

UNIVERZITET U SARAJEVU
ELEKTROTEHNIČKI FAKULTET
ODSJEK ZA RAČUNARSTVO I INFORMATIKU

Projekat iz predmeta Paralelni računarski sistemi

Poravnanje sekvenci i mapiranje očitanja

Studenti:

Alispahić Amina

Biber Maida

Halilović Elvedina

Ćenanović Nejla

Sadržaj

Uvod 2
Poravnanje bioloških sekvenci 4
Sistem bodovanja poravnanja 4
Globalno i lokalno poravnanje 5
Smith–Waterman algoritam 7
Praktični primjer: Smith–Waterman algoritam 7
Read mapping 9
Razlika između read mappinga i poravnanja sekvenci 9
Princip rada read mappinga 10
Uloga Smith-Waterman algoritma u read mappingu 11
Uticaj dužine k-mere na efikasnost mapiranja 11
Ograničenja read mappinga 12
Reference 13

Uvod

Poređenje bioloških sekvenci jedan je od temeljnih problema bioinformatike. Molekule DNK, RNK i proteina mogu se predstaviti kao nizovi znakova - A, C, G, T za DNK; A, G, C i U za RNK, odnosno 20 aminokiselina za proteine, a sličnost tih nizova često ukazuje na zajedničko evolucijsko porijeklo ili srodnu biološku funkciju. Poravnanje sekvenci (engl. *sequence alignment*) je postupak kojim se dvije ili više sekvenci postavljaju jedna naspram druge tako da se istakne njihova sličnost, uz dozvoljene supstitucije, umetanja i brisanja znakova (engl. *gaps*). Svako poravnanje se vrednuje funkcijom bodovanja koja nagrađuje poklapanja, a kažnjava nepoklapanja i praznine.

Prvi pristup ovom problemu predstavili su Needleman i Wunsch, koji su globalno poravnanje formulisali kao problem dinamičkog programiranja nad matricom sličnosti. Smith i Waterman su 1981. godine ovu ideju proširili na lokalno poravnanje, odnosno traženje para podsekvenci s maksimalnom sličnošću, uz dozvoljene praznine proizvoljne dužine. Ključna izmjena je uvođenje nule u rekurentnu relaciju, čime se negativni međurezultati odbacuju, a rješenje se traži kao najveći element matrice, a ne kao njen posljednji element. Ovakav pristup garantuje optimalno lokalno poravnanje, ali po cijenu vremenske složenosti proporcionalne proizvodu dužina sekvenci, tj.$O(n \cdot m)$.

Sa razvojem tehnologija sekvenciranja sljedeće generacije (engl. *next-generation sequencing*, NGS), značaj ovog problema se dramatično povećao. Savremeni sekvenceri proizvode stotine miliona do milijardi kratkih očitanja (engl. *reads*) dužine od nekoliko desetina do nekoliko stotina baza, a ona se moraju smjestiti u referentni genom koji, u slučaju čovjeka, ima oko tri milijarde baza. Taj zadatak naziva se mapiranje očitanja (engl. *read mapping*). Primjena Smith-Waterman algoritma između svakog očitanja i cijelog genoma je računski neizvodljiva, pa se u praksi koriste indeksne strukture (heš tabele k-mera, sufiksni nizovi, Burrows-Wheelerova transformacija i FM-indeks) i strategija *seed-and-extend*. Njome se najprije brzo pronalaze kandidat-pozicije na osnovu kratkih tačnih poklapanja, a zatim se tačno poravnanje računa samo nad malim okolnim regijama. Ovakvu strategiju koriste alati poput BLAST-a, BWA-a i Bowtie-ja.

Čak i uz ovakve heuristike, poravnanje ostaje jedno od računski najzahtjevnijih koraka u analizi genomskih podataka. Zbog toga je ovaj problem pogodan za primjenu paralelnog računanja. S jedne strane, mapiranje svakog očitanja je neovisno od ostalih, što omogućava paralelizam po podacima (engl. *data parallelism*) na višejezgrenim procesorima, klasterima i grafičkim procesorima. S druge strane, i unutar jednog poravnanja moguće je ostvariti paralelizam, jer su ćelije matrice na istoj anti-dijagonali međusobno neovisne i mogu se računati istovremeno.

Glavne primjene u praksi

- Otkrivanje evolucijskih veza: Praćenje kako su se geni mijenjali kroz vrijeme i slaganje filogenetskih (porodičnih) stabala živih bića.

- Identifikacija funkcije gena: Ako nepoznata sekvenca DNK ima visoko poravnanje s poznatim genom neke druge vrste, vjerojatno obavlja sličnu funkciju.
- Pronalaženje mutacija: Otkrivanje promjena u ljudskom genomu koje uzrokuju nasljedne bolesti ili rak (usporedbom s referentnim ljudskim genomom).

Poravnanje bioloških sekvenci

Poravnanje bioloških sekvenci (*sequence alignment*) predstavlja postupak poređenja dvije ili više DNK, RNK ili proteinskih sekvenci s ciljem identifikacije njihovih međusobnih sličnosti i razlika. Sekvence se postavljaju jedna ispod druge tako da se njihovi odgovarajući elementi nalaze u istim kolonama, čime se omogućava prepoznavanje podudarnih i različitih dijelova. Kod DNK sekvenci porede se nizovi nukleotida označenih slovima A, T, C i G. U ovom projektu razmatra se parno poravnanje (*pairwise alignment*), odnosno poređenje dvije DNK sekvence [1]

Prilikom poravnanja razlikuju se tri osnovna slučaja:

- Podudaranje (*match*) nastaje kada se na odgovarajućim pozicijama nalaze identični nukleotidi.

- Nepodudaranje (*mismatch*) označava različite nukleotide na tim pozicijama i može odgovarati zamjeni (*substitution*) jednog nukleotida drugim.

- Praznina (*gap*) predstavlja mjesto koje se uvodi u jednu od sekvenci kako bi se omogućilo bolje poravnanje njihovih elemenata. Praznine se obično označavaju znakom „-“ i mogu predstavljati umetanje (*insertion*) ili brisanje (*deletion*) nukleotida u odnosu na drugu sekvencu [1]

Na taj način moguće je prepoznati slične dijelove sekvenci čak i kada one nisu potpuno identične ili se razlikuju po dužini. Poravnanje sekvenci zato predstavlja važan postupak u bioinformatici, posebno pri analizi genetskih sličnosti i pronalaženju odgovarajućih regija između različitih DNK sekvenci [1]

Sistem bodovanja poravnanja

Za procjenu kvaliteta poravnanja koristi se sistem bodovanja (*scoring system*), kojim se određuju vrijednosti za podudaranja, nepodudaranja i praznine. Podudaranjima se najčešće dodjeljuju pozitivni bodovi, dok se nepodudaranja kažnjavaju negativnim bodovima. Uvođenje praznine također podrazumijeva određenu kaznu (*gap penalty*), kako bi se izbjeglo nepotrebno umetanje praznina radi povećanja broja podudaranja [1]

Ukupan rezultat poravnanja (*alignment score*) određuje se na osnovu dodijeljenih bodova. Cilj algoritma jeste pronaći poravnanje koje ostvaruje najveći rezultat prema odabranom sistemu bodovanja. Veći rezultat ukazuje na povoljnije poravnanje u okviru primijenjenog modela, ali ne predstavlja sam po sebi dokaz biološke povezanosti sekvenci.

Vrijednosti koje se dodjeljuju podudaranjima, nepodudaranjima i prazninama zavise od odabranog sistema bodovanja. Njihov izbor utiče na ukupni rezultat i na poravnanje koje će algoritam pronaći.

Globalno i lokalno poravnanje

Prema dijelu sekvenci koji se nastoji poravnati razlikuju se dva osnovna pristupa: globalno i lokalno poravnanje.

Globalno poravnanje (global alignment) nastoji poravnati dvije sekvence duž njihove cjelokupne dužine. Ovaj pristup posebno je pogodan za poređenje sekvenci koje su približno jednake dužine i imaju visok stepen međusobne sličnosti. Jedan od najpoznatijih algoritama za globalno poravnanje jeste Needleman–Wunsch algoritam, koji koristi dinamičko programiranje za pronalaženje optimalnog poravnanja prema definisanom sistemu bodovanja [2].

Za razliku od globalnog, lokalno poravnanje (local alignment) usmjereno je na pronalaženje najsličnijih dijelova dvije sekvence, bez potrebe za njihovim poravnanjem u cjelini. Ovaj pristup posebno je koristan kada se sekvence značajno razlikuju po dužini ili kada se očekuje da se sličnost nalazi samo u određenim regijama. Jedan od osnovnih algoritama za lokalno poravnanje jeste Smith–Waterman algoritam, koji primjenjuje dinamičko programiranje kako bi pronašao optimalno lokalno poravnanje prema odabranom sistemu bodovanja [3].

Poređenje algoritama Needleman–Wunsch i Smith–Waterman

Smith–Waterman algoritam predstavlja izmjenu Needleman–Wunsch algoritma. Oba algoritma koriste dinamičko programiranje, matricu bodovanja, sistem bodova za podudaranja, nepodudaranja i praznine te postupak traceback [1]. Razlikuju se u tri ključna koraka, što je prikazano u Tabeli 1.

	Needleman–Wunsch	**Smith–Waterman**
Vrsta poravnanja	globalno (cijele sekvence)	lokalno (najsličniji dijelovi)
Inicijalizacija prvog reda i prve kolone	kumulativne kazne za praznine	nule
Računanje ćelije	maksimum tri vrijednosti (dijagonala, gore, lijevo); rezultat može biti negativan	maksimum iste tri vrijednosti i nule; negativan rezultat se zamjenjuje nulom
Traceback	od donjeg desnog ugla do gornjeg lijevog ugla	od ćelije s najvećom vrijednošću do ćelije s vrijednošću nula
Pogodno za	sekvence slične dužine i visoke sličnosti	sekvence različite dužine ili sličnost samo u pojedinim regijama

Najvažnija razlika jeste uvođenje nule u Smith–Waterman algoritmu. Kada rezultat neke ćelije postane negativan, to znači da sekvence do te pozicije nemaju sličnosti, pa se vrijednost postavlja na nulu i uticaj ranijeg dijela poravnanja se odbacuje. Time se omogućava da novo

poravnanje počne na bilo kojoj poziciji obje sekvence. Nule u prvom redu i prvoj koloni imaju sličnu ulogu: dozvoljavaju da poravnanje počne bilo gdje, jer krajnje praznine nisu kažnjene. Kod Needleman–Wunsch algoritma krajnje praznine se kažnjavaju, jer poravnanje mora obuhvatiti obje sekvence u cjelini [2]. Obje varijante imaju istu vremensku složenost, pa izbor algoritma ne zavisi od brzine, već od vrste problema.

Lokalno poravnanje posebno je značajno za problem mapiranja DNK očitanja (*read mapping*), koji se razmatra u ovom projektu. Pri mapiranju se kratka DNK očitanja nastoje povezati s odgovarajućim pozicijama unutar znatno duže referentne sekvence. Budući da kratko očitanje predstavlja samo mali dio referentne sekvence, nije potrebno poravnati obje sekvence u njihovoj ukupnoj dužini, već pronaći regiju reference koja najbolje odgovara očitanju.

Zbog toga je za projekat Sequence Alignment and Read Mapping odabran Smith–Waterman algoritam, koji omogućava pronalaženje optimalnog lokalnog poravnanja između očitanja i odgovarajuće regije referentne sekvence, uz uvažavanje mogućih zamjena, umetanja i brisanja nukleotida.

Smith–Waterman algoritam

Smith–Waterman algoritam koristi dinamičko programiranje kako bi pronašao lokalno poravnanje s najvećim rezultatom između dvije sekvence. Umjesto da posebno računa rezultat za svako moguće poravnanje, algoritam rješava niz manjih podproblema i njihove rezultate čuva u matrici. Svaka nova vrijednost izračunava se koristeći vrijednosti koje su već upisane u matricu. [1] [3]
Neka su dvije sekvence označene kao X i Y, a njihovi znakovi kao x_i i y_j. Formira se matrica H, čiji broj redova i kolona odgovara dužinama sekvenci, uz dodatni početni red i kolonu. Vrijednost $H_{i,j}$ predstavlja najbolji rezultat lokalnog poravnanja koje završava na poziciji *i* u sekvenci X i poziciji *j* u sekvenci Y. [3]
Prvi red i prva kolona matrice popunjavaju se nulama. Time se omogućava da se lokalno poravnanje može započeti na različitim pozicijama sekvenci, a ne samo od njihovog početka. Nakon inicijalizacije, algoritam popunjava ostale ćelije, red po red ili kolonu po kolonu, tako da su potrebne vrijednosti iz prethodnih ćelija već izračunate. [3]

Za izračunavanje vrijednosti $H_{i,j}$, algoritam razmatra tri načina na koja poravnanje može stići do te ćelije. Prva mogućnost je da se znakovi x_i i y_j poravnaju jedan s drugim, pa se njihov bod ili kazna dodaje rezultatu iz dijagonalne ćelije $H_{i-1,j-1}$. Druga mogućnost je dodavanje praznine u jednoj sekvenci, što odgovara ćeliji iznad $H_{i-1,j}$. Treća mogućnost je dodavanje praznine u drugoj sekvenci, što odgovara ćeliji slijeva $H_{i,j-1}$. [3]

$$H_{i,j} = \max\left\{H_{i-1,j-1} + s(x_i, y_j), H_{i-1,j} - g, H_{i,j-1} - g, 0\right\}$$

U ovoj formuli, $s(x_i,y_j)$ označava rezultat poređenja dva znaka: podudaranje može donijeti bodove, a nepodudaranje kaznu. Vrijednost g označava kaznu za prazninu. Nula je uključena zato što algoritam ne nastavlja poravnanje s negativnim rezultatom; umjesto toga, takav rezultat odbacuje i može započeti novo lokalno poravnanje. [1] [3]

Za svaku ćeliju upisuje se najveća od ponuđenih vrijednosti. Na taj način se u matrici čuva najbolji rezultat za svaku moguću kombinaciju pozicija u dvije sekvence. Kada je matrica popunjena, najveća vrijednost u cijeloj matrici predstavlja rezultat najboljeg lokalnog poravnanja. [3]

Da bi se otkrilo koje su sekvence proizvele taj rezultat, koristi se postupak *traceback*. Počinje se u ćeliji s najvećom vrijednošću i prati se prethodna ćelija iz koje je svaki rezultat izračunat. Dijagonalni korak označava poravnanje dva znaka, a korak prema gore ili ulijevo označava prazninu u jednoj od sekvenci. Postupak se zaustavlja kada se dođe do ćelije s vrijednošću nula; tako se određuju početak i kraj pronađenog lokalnog poravnanja. [3]

Praktični primjer: Smith–Waterman algoritam

Poravnat ćemo sekvence **AGC** i **AC**. Koristit ćemo sljedeće vrijednosti:

- Podudaranje: **+3**

- Nepodudaranje: **−2**
- Kazna za prazninu: **−1**

Redovi matrice predstavljaju sekvencu **AGC**, a kolone sekvencu **AC**. Prvi red i prva kolona popunjavaju se nulama.

	–	A	C
–	0	0	0
A	0	3	2
G	0	2	1
C	0	1	**5**

Svaku ćeliju računamo tako što izračunamo četiri moguće vrijednosti i odaberemo najveću:

1. Poređenje A i A — podudaranje

H(A,A) = max(0 + 3, 0 − 1, 0 − 1, 0) = **3**

2. Poređenje A i C — nepodudaranje

H(A,C) = max(0 − 2, 0 − 1, 3 − 1, 0) = **2**

3. Poređenje G i A — nepodudaranje

H(G,A) = max(0 − 2, 3 − 1, 0 − 1, 0) = **2**

4. Poređenje G i C — nepodudaranje

H(G,C) = max(3 − 2, 2 − 1, 2 − 1, 0) = **1**

5. Poređenje C i A — nepodudaranje

H(C,A) = max(0 − 2, 2 − 1, 0 − 1, 0) = **1**

6. Poređenje C i C — podudaranje

H(C,C) = max(2 + 3, 1 − 1, 1 − 1, 0) = **5**

Najveća vrijednost u matrici je **5**. Traceback počinje od te ćelije i prati prethodne vrijednosti do nule. Dobijeno poravnanje je:

A G C
A - C

Ukupan rezultat poravnanja je **+3 − 1 + 3 = 5**.

Read mapping

Savremene tehnologije sekvenciranja DNK generišu veliki broj kratkih sekvenci koje predstavljaju dijelove izvornog genoma. Te sekvence nazivaju se *readovi*, a njihova dužina zavisi od korištene tehnologije sekvenciranja. Kod tehnologija kratkih očitavanja (*short-read sequencing*) tipična dužina readova iznosi približno 100 do 150 nukleotida. Nakon procesa sekvenciranja dobija se veliki skup readova, pri čemu njihovo prvobitno mjesto u genomu nije poznato.

Read mapping predstavlja računarski postupak određivanja pozicije na referentnom genomu kojoj odgovara svaki pojedinačni read. Referentni genom je unaprijed poznata sekvenca DNK koja služi kao osnova za poređenje i određivanje porijekla dobijenih readova. Cilj postupka je pronaći odgovarajuće pozicije uzimajući u obzir moguće razlike između readova i referentne sekvence.

Pronalaženje odgovarajuće pozicije nije jednostavan postupak jer readovi ne moraju biti identični dijelovima referentnog genoma. Odstupanja mogu nastati usljed grešaka tokom sekvenciranja, genetskih varijacija između pojedinaca, kao i insercija i delecija nukleotida. Zbog toga algoritmi za read mapping moraju podržavati približno poklapanje (*approximate matching*), odnosno pronalaženje pozicija na kojima se read najbolje podudara s referentnom sekvencom, uz dozvoljene razlike.

Rezultati read mappinga predstavljaju osnovu za niz daljnjih bioinformatičkih analiza, uključujući identifikaciju genetskih varijanti, otkrivanje mutacija, analizu genetskih bolesti i proučavanje strukture i funkcije genoma.

Razlika između read mappinga i poravnanja sekvenci

Read mapping i poravnanje sekvenci (engl. *sequence alignment*) predstavljaju povezane, ali različite računarske probleme.

Poravnanje sekvenci podrazumijeva određivanje optimalnog načina međusobnog poklapanja dvije ili više sekvenci, pri čemu se uzimaju u obzir podudaranja, nepodudaranja, insercije i delecije. Jedan od poznatih algoritama za rješavanje ovog problema je Smith-Waterman algoritam, koji primjenom dinamičkog programiranja pronalazi optimalno lokalno poravnanje dvije sekvence.

Za razliku od toga, read mapping podrazumijeva pronalaženje odgovarajućih pozicija velikog broja readova unutar znatno duže referentne sekvence. Dok se kod klasičnog poravnanja posmatraju dvije zadate sekvence, kod read mappinga potrebno je obraditi milione readova i za svaki od njih pronaći odgovarajuću lokaciju u referentnom genomu, koji može sadržavati nekoliko milijardi nukleotida.

Direktna primjena algoritma Smith-Waterman na svaki read i cjelokupan referentni genom bila bi računski veoma zahtjevna. Njegova vremenska složenost iznosi (O(mn)), gdje su (m) i

(n) dužine sekvenci koje se poravnavaju. Kada se uzme u obzir veliki broj readova i veličina referentnog genoma, takav pristup postaje nepraktičan.

Zbog toga savremeni alati za read mapping koriste optimizovane pristupe kojima se prostor pretrage najprije značajno smanjuje, a zatim se nad odabranim kandidatima primjenjuju precizniji algoritmi poravnanja. Na taj način read mapping predstavlja širi postupak koji, između ostalog, koristi algoritme za poravnanje sekvenci kao jednu od svojih komponenti.

Princip rada read mappinga

Jedan od često korištenih pristupa u algoritmima za read mapping jeste *seed-and-extend* strategija, koja razdvaja postupak pronalaženja potencijalnih pozicija od njihovog preciznog poravnanja. [4]

Postupak se može predstaviti kroz tri osnovne faze:

1. Indeksiranje referentnog genoma

Prije obrade readova vrši se predobrada referentnog genoma, pri čemu se formira indeks koji omogućava efikasno pronalaženje određenih podsekvenci. Jedan od pristupa je korištenje k-mera, odnosno podsekvenci fiksne dužine (k), koje se izdvajaju iz referentnog genoma. Njihove pozicije pohranjuju se u odgovarajuću strukturu podataka, kao što je hash tabela.

Na ovaj način omogućava se brzo pronalaženje pozicija na kojima se određena podsekvenca pojavljuje, bez potrebe za ponovnim pretraživanjem cjelokupnog genoma. Indeks se formira jednom i koristi tokom obrade svih readova.

2. Pronalaženje kandidatskih pozicija (seeding)

U ovoj fazi iz svakog reada izdvajaju se kraće podsekvence koje se nazivaju *seedovi*. Njihovim pretraživanjem u prethodno formiranom indeksu pronalaze se potencijalne pozicije na referentnom genomu.

Podudaranje pojedinačnih seedova predstavlja osnovu za određivanje kandidatskih regija. Ukoliko se više seedova iz istog reada pronađe na međusobno odgovarajućim pozicijama referentnog genoma, takva regija predstavlja vjerovatnog kandidata za dalje poravnanje.

Korištenjem više seedova smanjuje se zavisnost od pojedinačnih podudaranja, što je posebno značajno u slučajevima kada read sadrži greške ili genetske varijacije.

3. Precizno poravnanje (extension)

Nakon određivanja kandidatskih regija vrši se preciznije poravnanje reada s odgovarajućim dijelovima referentnog genoma. U ovoj fazi primjenjuju se algoritmi koji uzimaju u obzir podudaranja, nepodudaranja i moguće insercije i delecije.

Jedan od algoritama koji se može koristiti za ovu svrhu jeste Smith-Waterman algoritam. On primjenom dinamičkog programiranja određuje optimalno lokalno poravnanje između reada i odabrane regije. Na osnovu rezultata poravnanja procjenjuje se kvalitet svakog kandidatskog mjesta, nakon čega se određuje najvjerovatnija pozicija reada.

Potrebno je uzeti u obzir i dodatne specifičnosti genomskih podataka. Budući da je DNK građena od dva komplementarna lanca, read se može poravnati u jednom ili drugom smjeru. Također, ponavljajuće regije genoma mogu dovesti do toga da se isti read sličnom kvalitetom poravna na više različitih pozicija. Takvi slučajevi predstavljaju višestruko ili nejednoznačno mapiranje (*multi-mapping*).

Uloga Smith-Waterman algoritma u read mappingu

Smith-Waterman algoritam predstavlja jednu od mogućih metoda za precizno lokalno poravnanje sekvenci unutar postupka read mappinga. Njegova osnovna uloga jeste određivanje kvaliteta poklapanja između reada i kandidatske regije referentnog genoma.

Dok se fazama indeksiranja i pronalaženja seedova smanjuje prostor pretrage i određuju potencijalne lokacije, Smith-Waterman omogućava detaljnije poređenje odabranih sekvenci. Time se izbjegava potreba za njegovom direktnom primjenom na cjelokupan referentni genom.

Računska zahtjevnost poravnanja predstavlja jedan od važnih izazova u obradi velikog broja readova. Svaki read može imati više kandidatskih regija koje je potrebno dodatno provjeriti, što može rezultirati velikim brojem operacija poravnanja. Zbog toga je efikasnost ove faze značajna za ukupne performanse read mapping postupka.

Ova karakteristika čini read mapping interesantnim problemom za primjenu paralelnog programiranja, posebno kada se veliki broj nezavisnih readova obrađuje istovremeno.

Uticaj dužine k-mere na efikasnost mapiranja

Izbor dužine k-mere predstavlja važan parametar koji utiče na efikasnost i pouzdanost postupka read mappinga. Vrijednost k određuje dužinu podsekvenci koje se izdvajaju iz readova i referentnog genoma tokom faze indeksiranja i pronalaženja seedova.

Manje vrijednosti k povećavaju vjerovatnoću pronalaženja podudaranja između readova i referentnog genoma, čak i u prisustvu grešaka u sekvenciranju. Međutim, kraće podsekvence češće se pojavljuju na različitim pozicijama genoma, što može rezultirati većim brojem kandidatskih regija koje je potrebno dodatno provjeriti.

S druge strane, veće vrijednosti k smanjuju vjerovatnoću slučajnih podudaranja i omogućavaju preciznije izdvajanje kandidatskih pozicija. Ipak, ukoliko se unutar seeda nalazi greška u sekvenciranju ili genetska varijacija, podudaranje možda neće biti pronađeno. Zbog toga izbor vrijednosti k predstavlja kompromis između osjetljivosti pretrage i broja kandidatskih pozicija koje je potrebno obraditi.

Ograničenja read mappinga

Uprkos optimizacijama koje omogućavaju efikasnu obradu velikog broja readova, read mapping ima određena ograničenja. Kvalitet rezultata zavisi od tačnosti referentnog genoma, kvaliteta sekvenciranja i sposobnosti algoritma da prepozna razlike između readova i referentne sekvence.

Poseban izazov predstavljaju ponavljajuće regije genoma, u kojima se iste ili veoma slične sekvence pojavljuju na više različitih lokacija. U takvim slučajevima pojedini readovi mogu imati više potencijalnih pozicija mapiranja, zbog čega nije uvijek moguće jednoznačno odrediti njihovo porijeklo. Dodatne poteškoće mogu nastati usljed većeg broja grešaka, insercija i delecija, kao i nedovoljno zastupljenih ili potpuno odsutnih regija u referentnom genomu.

Ova ograničenja pokazuju da efikasnost read mappinga ne zavisi isključivo od brzine algoritma, nego i od njegove sposobnosti da pronađe pouzdane pozicije uprkos biološkim varijacijama i nesavršenostima ulaznih podataka.

Reference

[1] S. R. E. A. K. a. G. M. R. Durbin, u *Biological Sequence Analysis: Probabilistic Models of Proteins and Nucleic Acids.*, Cambridge: Cambridge University Press, 1998.

[2] S. B. N. a. C. D. Wunsch, "A general method applicable to the search for similarities in the amino acid sequence of two proteins," *Journal of Molecular Biology.*

[3] T. F. S. a. M. S. Waterman, "Identification of common molecular subsequences," *Journal of Molecular Biology.*

[4] H. L. i. N. Homer, "A survey of sequence alignment algorithms for next-generation sequencing," *Briefings in Bioinformatics 11,* 2010.